Taller 1: Análisis Predictivo y Aprendizaje Estadístico. Caso de Estudio: Advertising Data

Juan Sebastian Salina Moscote - 122301

Carlos Fernando Vargas Sierra - 122041

Haider Camilo Villalba Santos - 122301

Universidad ECCI

Sistemas Avanzados de la Producción

Docente: Fredy Alexander Orjuela Lopez

Bogotá, Colombia

2026

Introducción

El presente trabajo tiene como propósito aplicar técnicas de análisis predictivo y aprendizaje estadístico para estudiar la relación entre la inversión publicitaria y el comportamiento de las ventas, utilizando el conjunto de datos Advertising Data como caso de estudio. A través de herramientas estadísticas y modelos de aprendizaje automático, se busca comprender cómo diferentes medios de publicidad influyen en los resultados comerciales y qué tan efectivas son estas inversiones para explicar y predecir las ventas.

En una primera fase, se realizó un análisis estadístico descriptivo y exploratorio con el fin de caracterizar las variables, identificar patrones de distribución, detectar posibles valores atípicos y evaluar la asociación entre las variables mediante medidas de correlación. Posteriormente, se implementó un modelo de regresión lineal múltiple para cuantificar el impacto de cada medio publicitario sobre las ventas y analizar la calidad del ajuste del modelo.

Fase 1: Estadística Descriptiva y Análisis Exploratorio.

1. Caracterización Numérica:

Variable	**Media (Mean)**	**Mediana (Median)**	**Desv. Estándar (Std)**	**Mínimo (Min)**	**Máximo (Max)**	**Asimetría (Skewness)**	**Curtosis (Kurtosis)**
TV	147.0425	149.75	85.854236	0.7	296.4	-0.069853	-1.226495
Radio	23.2640	22.90	14.846809	0.0	49.6	0.094175	-1.260401
Newspaper	30.5540	25.75	21.778621	0.3	114.0	0.894720	0.649502
Sales	14.0225	12.90	5.217457	1.6	27.0	0.407571	-0.408869

Tabla [1]: Está tabla muestra las medidas de tendencia central y dispersión para las variables independientes y la variable ‘Sales’ dependiente.

2. Análisis de Distribución y Atípicos:

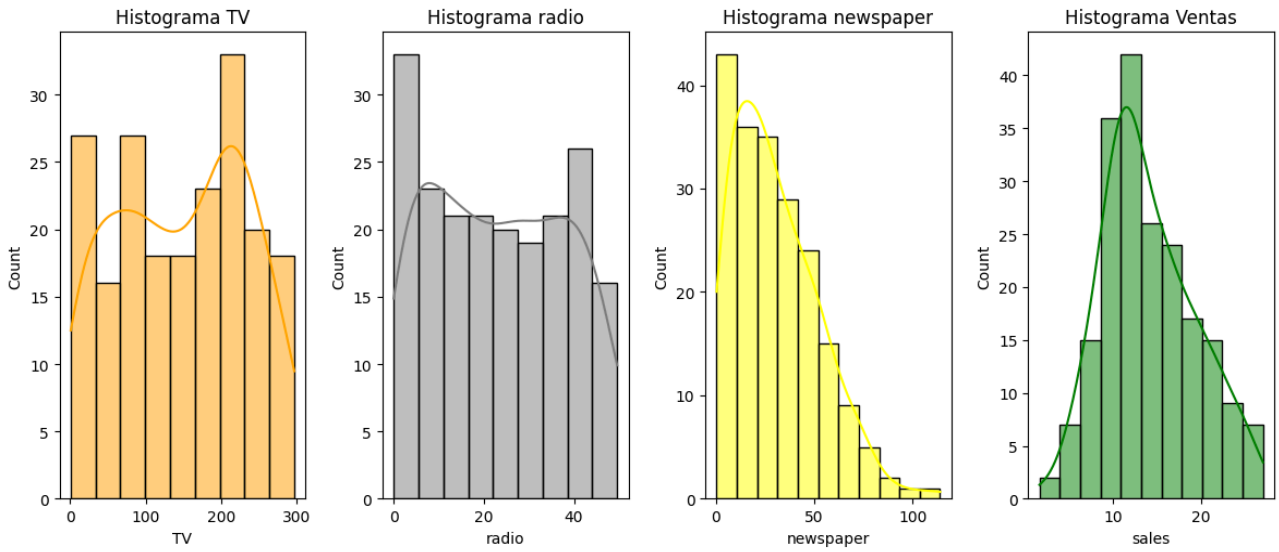

Figura [1]: En las gráficas anteriores se pueden encontrar los histogramas

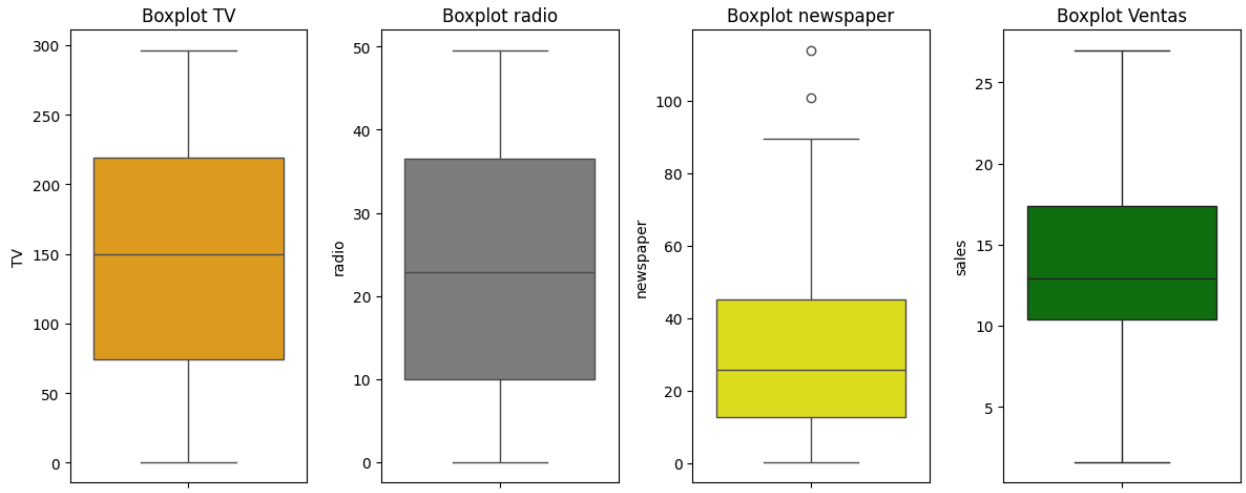

Figura [2]: En las gráficas anteriores se puede encontrar

Determinación de asimetría de las distribuciones. El primer valor (-0.069853) es muy cercano a cero, lo que indica que la distribución es prácticamente simétrica. Aunque el signo negativo sugiere una ligera inclinación hacia la izquierda, esta es mínima y no representa un sesgo significativo en los datos. El segundo valor (0.094175) también se encuentra muy próximo a cero. Esto significa que la distribución es prácticamente simétrica, con una leve tendencia hacia la derecha. Sin embargo, esta asimetría es tan pequeña que no afecta de manera importante la forma de la distribución. El tercer valor (0.894720) muestra una asimetría positiva moderada. Esto indica que la distribución presenta una cola más larga hacia la derecha, es decir, existen algunos valores altos que se alejan del promedio y desplazan la media hacia valores mayores. El cuarto valor (0.407571) refleja una asimetría positiva leve. La distribución está ligeramente inclinada hacia la derecha, lo que significa que hay algunos valores superiores al promedio que generan una pequeña desviación, aunque no es pronunciada. Teniendo en cuenta la regla general para interpretar el sesgo:

- Skewness ≈ 0 → Distribución simétrica
- Entre -0.5 y 0.5 → Asimetría leve
- Entre 0.5 y 1 (o -0.5 y -1) → Asimetría moderada
- Mayor que 1 (o menor que -1) → Asimetría fuerte

En general, los datos presentan distribuciones mayormente simétricas o con asimetrías positivas leves a moderadas, sin evidenciar sesgos extremos.

Sí, es posible que existan datos atípicos, especialmente en las variables con asimetría positiva moderada, lo que indica la presencia de valores altos que se alejan del resto de los datos.

Estos valores extremos pueden influir significativamente en la línea de regresión, ya que el método de mínimos cuadrados les da mayor peso. Como resultado, la pendiente y el intercepto pueden verse afectados, distorsionando la relación real entre las variables y reduciendo la precisión del modelo.

3. Evaluación de Asociación:

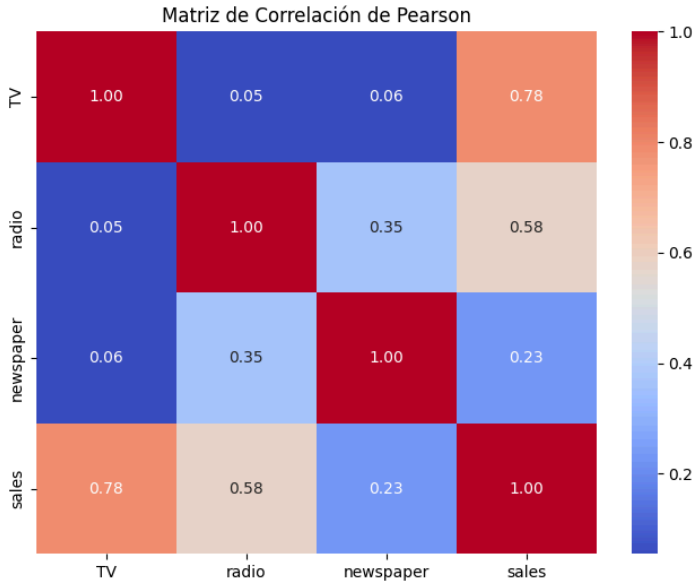

Figura [3]: En la figura anterior se puede observar la matriz de correlación de Pearson.

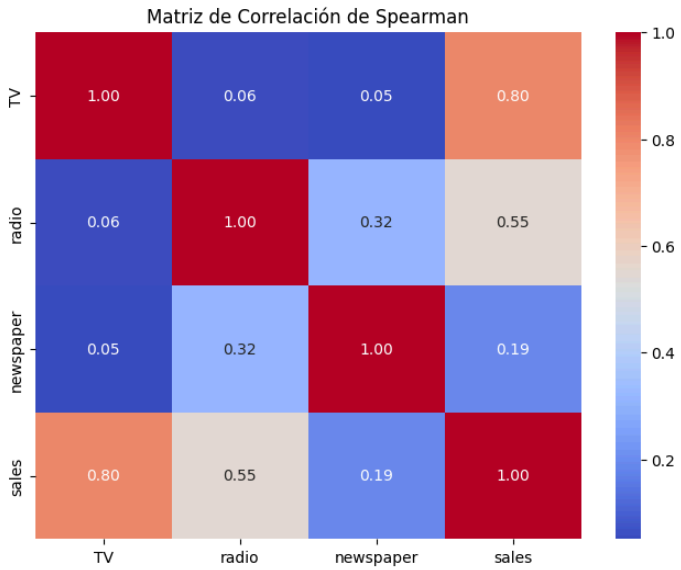

Figura [4]: En la figura anterior se puede observar la matriz de correlación de Spearman.

Un coeficiente de correlación cercano a 1 indica una relación positiva fuerte entre la inversión publicitaria y las ventas: a medida que aumenta la inversión en un medio, también aumentan las ventas de manera consistente. En el contexto del marketing, esto sugiere que ese canal publicitario tiene un alto impacto en el retorno en ventas. Por otro lado, un coeficiente cercano a −1 indicaría una relación negativa fuerte, es decir, que al aumentar la inversión las ventas disminuyen, lo cual sería un comportamiento inverso y poco común en este contexto.

Un valor de correlación cercano a 0 indica que no existe una relación lineal clara entre las variables. En términos prácticos, significa que aumentar la inversión en ese medio no está asociado de manera consistente con cambios en las ventas.

Al comparar los coeficientes de Pearson y Spearman, se observa que los valores son muy similares (por ejemplo, TV–sales ≈ 0.78 en Pearson y ≈ 0.80 en Spearman; radio–sales ≈ 0.58 y ≈ 0.55). Esta similitud sugiere que la relación no solo es monotónica sino también

aproximadamente lineal. Si existieran relaciones no lineales fuertes pero monotónicas, Spearman sería alto mientras que Pearson sería considerablemente menor. Como ambos coeficientes son cercanos, los resultados indican que las relaciones observadas, especialmente entre TV y ventas, tienden a ser bastante lineales, lo cual se confirma con la forma de la nube de puntos, que muestra una tendencia creciente relativamente recta y sin curvaturas marcadas.

Fase 2: Regresión Lineal y Diagnóstico

1. **Modelamiento Múltiple:**

Intercepto (beta_0): 2.9389

Pendiente (beta_1): 0.0458

Pendiente (beta_2): 0.1885

Pendiente (beta_3): -0.0010

2. **Interpretación de Parámetros:**

A continuación, se presenta la interpretación de los coeficientes del modelo de regresión lineal múltiple:

Intercepto ($\hat{\beta}_0$ = 2.9389)

El intercepto representa el valor esperado de las ventas cuando la inversión en “TV, radio y newspaper es igual a cero”. En este caso, el modelo estima que las ventas serían aproximadamente “2.94 unidades” aún sin inversión publicitaria.

Conceptualmente, sí puede tener sentido que sea diferente de cero, ya que las ventas no dependen exclusivamente de la publicidad; pueden existir otros factores como posicionamiento de marca, clientes habituales, ubicación o demanda natural del producto que generen ventas incluso sin inversión en medios.

Coeficiente $\hat{\beta}_1$ (TV = 0.0458)

Este coeficiente indica que, “manteniendo constantes la inversión en radio y newspaper (ceteris paribus)”, un aumento de una unidad monetaria en la inversión en TV incrementa en promedio las ventas en “0.0458 unidades”.

Es un efecto positivo, lo que sugiere que la publicidad en TV contribuye al aumento de las ventas.

Coeficiente $\hat{\beta}_2$ (radio = 0.1885)

Manteniendo constantes las demás variables, un aumento de una unidad en la inversión en radio incrementa en promedio las ventas en “0.1885 unidades”.

Este efecto es mayor que el de TV, lo que sugiere que, por unidad invertida, la radio tiene un impacto marginal más fuerte sobre las ventas.

Coeficiente $\hat{\beta}_3$ (newspaper = -0.0010)

Este coeficiente indica que, manteniendo constantes TV y radio, un aumento de una unidad en la inversión en newspaper disminuye las ventas en promedio en “0.0010 unidades”.

Sin embargo, el efecto es muy pequeño y prácticamente cercano a cero, lo que sugiere que la publicidad en prensa tiene un impacto muy débil o casi nulo sobre las ventas dentro de este modelo.

El modelo sugiere que “TV y radio influyen positivamente en las ventas”, siendo la radio el medio con mayor efecto marginal. En cambio, la inversión en newspaper no muestra un efecto relevante sobre la media de las ventas, manteniendo constantes las demás variables.

3. **Análisis de Bondad de Ajuste:**

Regresión lineal simple TV

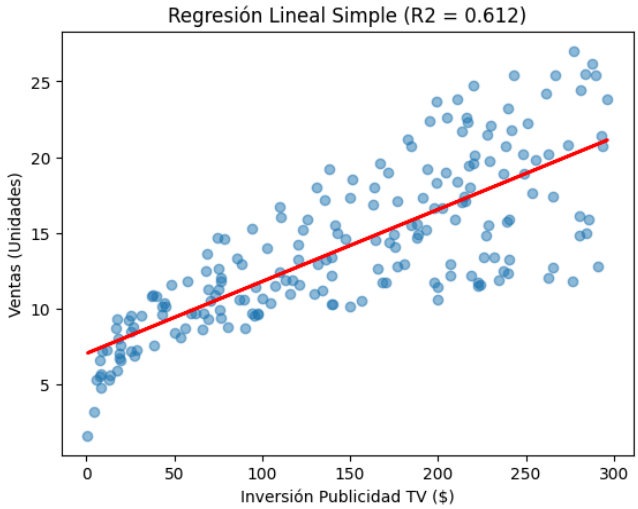

Figura [5]: En esta gráfica se puede observar la regresión simple en R2 vs las ventas para la inversión en la TV.

Regresión lineal simple Radio

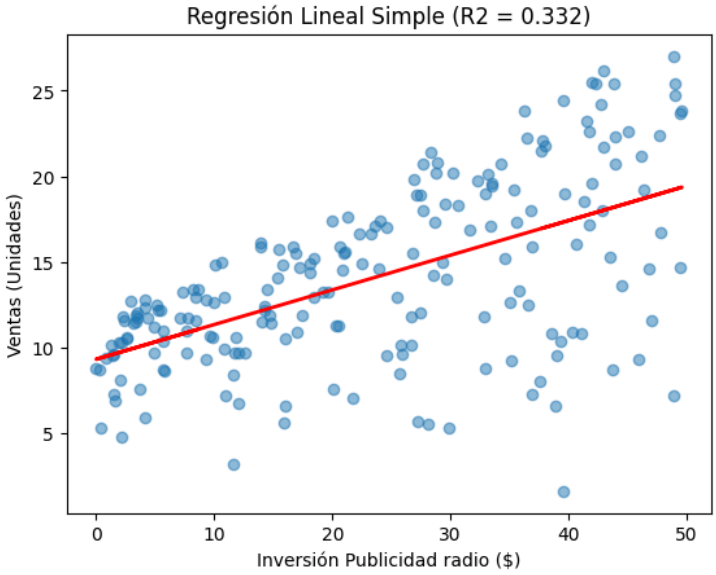

Figura [6]: En esta gráfica se puede observar la regresión simple en R2 vs las ventas para la inversión en la Radio.

Regresión lineal simple Newspaper

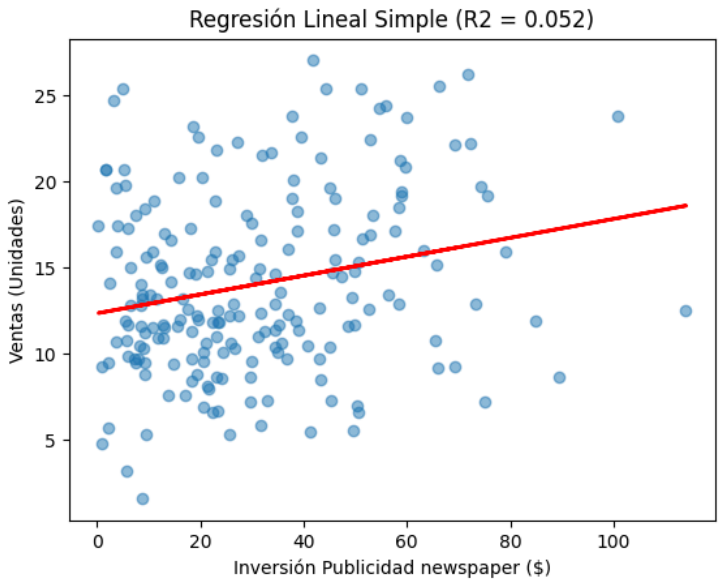

Figura [7]: En esta gráfica se puede observar la regresión simple en R2 vs las ventas para la inversión en el periodico.

Error Cuadrático Medio (MSE): 2.7841

Raíz del Error Cuadrático Medio (RMSE): 1.6686

R-cuadrado (R2): 0.8972

El R-cuadrado (R^2) = 0.8972 indica que el 89.72% de la variabilidad de las ventas es explicada por el modelo de regresión que incluye la inversión en TV, radio y newspaper.

En otras palabras, el modelo tiene un alto poder explicativo, ya que casi el 90% de los cambios observados en las ventas pueden atribuirse a las variaciones en la inversión publicitaria considerada en el modelo.

El 10.28% restante (100% − 89.72%) corresponde a factores no incluidos en el modelo, como otras estrategias de marketing, condiciones del mercado, competencia, estacionalidad u otros elementos externos.

En términos generales, un R^2 cercano a 1 indica un buen ajuste del modelo a los datos, por lo que este resultado sugiere que la regresión lineal múltiple describe adecuadamente la relación entre inversión publicitaria y ventas.

Estimación matricial

Estimación Matricial - Regresión Lineal Simple

Dadas las matrices:

X =

1	1
1	2
1	3
1	4
1	5

Y =

2

4

6

7

9

1. Matriz Transpuesta X'

X' =

1	1	1	1	1
1	2	3	4	5

2. Producto X'X

X'X =

5	15

15	55

3. Inversa (X'X)^(-1)

(X'X)^(-1) =

55/50	-15/50
-15/50	5/50

(X'X)^(-1) = (1/50) * [[55, -15], [-15, 5]]

(X'X)^(-1) = [[1.1, -0.3], [-0.3, 0.1]]

4. Producto X'Y

X'Y = [28, 106]

5. Estimadores β̂

β̂ = (X'X)^(-1) X'Y

β̂ = [0.3, 1.7]

Intercepto (β̂0) = 0.3

Pendiente (β̂1) = 1.7

6. Ecuación estimada

$\hat{y} = 0.3 + 1.7x$

Fase 3: Árboles de Decisión y Comparación de Modelos

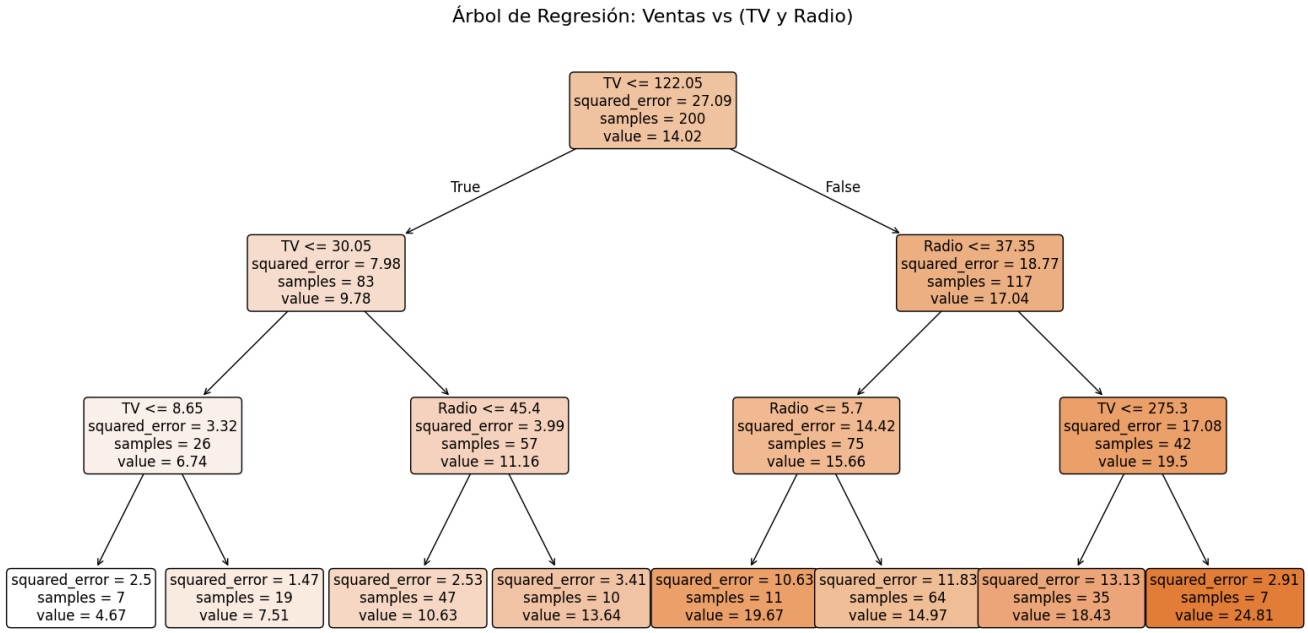

El árbol de regresión realiza su primera partición en la variable TV (TV ≤ 122.05), lo que indica que es la variable más importante para explicar las ventas.

Cuando la inversión en TV es baja (≤ 122.05), las ventas promedio son menores (≈ 9.78) y el modelo continúa dividiendo con TV y Radio para mejorar la precisión. Cuando la inversión en TV es alta (> 122.05), las ventas promedio aumentan (≈ 17.04) y la variable Radio cobra mayor relevancia en nuevas particiones.

En los nodos finales se muestra el número de observaciones, el promedio estimado de ventas y la variabilidad interna. Lo que indica que, TV es la variable más determinante y Radio complementa la explicación. El árbol no asume linealidad, sino que segmenta la inversión en

rangos que presentan comportamientos similares en ventas, facilitando la toma de decisiones publicitarias.

RESULTADOS COMPARATIVOS

Importancia en el Árbol (TV): 0.8241

Importancia en el Árbol (Radio): 0.1759

Coeficiente Regresión (TV): 0.0469

Coeficiente Regresión (Radio): 0.0442

Mercado	Inversión TV	Ventas (Clase)
1	Alta	Altas
2	Alta	Altas
3	Baja	Bajas
4	Baja	Altas

Total: 4 mercados

Clases:

- Altas = 3
- Bajas = 1

Probabilidades:

$p(Altas) = \frac{3}{4} = 0.75$

$p(Bajas) = \frac{1}{4} = 0.25$

Entropía del nodo padre:

$H(S) = -\sum pi \cdot log2(pi)$

$H(S) = \ - [0.75log2(0.75) + 0.25log2(0.25)]$

$H(S) = \ - [0.75(-0.415) + 0.25(-2)]$

$H(S) = \ - [-0.311 - 0.5]$

$H(S) = 0.811$

Entropía del Gini del nodo padre:

$Gini = 1 - (0.752 + 0.252)$

$Gini = 1 - (0.5625 + 0.0625)$

$Gini = 1 - 0.625$

$Gini = 0.375$

Ganancia de Información (Partición por Inversión TV)

Importancia de predictores:

Grupo 1: TV = Alta

2 casos → ambos Altas

Entropía = 0 (nodo puro)

Grupo 2: TV = Baja

2 casos → 1 Alta, 1 Baja

Probabilidades: 0.5 y 0.5

$$H =- [0.5log2(0.5) + 0.5log2(0.5)]$$

$$H = 1$$

Entropía ponderada después de la partición:

$$Hpart = (2/4)(0) + (2/4)(1)$$

$$Hpart = 0.5$$

Ganancia de Información:

$$IG = Hpadre - Hpart$$

$$IG = 0.811 - 0.5$$

$$IG = 0.311$$

Ganancia de Información ≈ 0.31

La variable Inversión TV reduce la incertidumbre en 0.31, lo que indica que tiene capacidad discriminativa para separar ventas Altas y Bajas.

Comparándolo con la regresión múltiple anterior:

- TV tenía un coeficiente positivo.
- La radio mostraba incluso mayor efecto marginal.

En el árbol de decisión previo, TV fue la primera partición, confirmando su alta importancia.

Diagnóstico Comparativo:

Un modelo de regresión lineal es preferible cuando:

- La relación es aproximadamente lineal.
- Se desea interpretar efectos marginales precisos.
- Se busca mayor capacidad predictiva continua.

Un árbol de decisión es preferible cuando:

- Existen relaciones no lineales.
- Se desea interpretación por reglas claras.
- Se requiere segmentación del mercado.

En términos de interpretabilidad, el árbol es más intuitivo. En precisión global (según $R^2 \approx 0.89$), la regresión lineal mostró muy buen desempeño para este problema.

Conclusiones

El análisis estadístico permitió identificar que las variables de inversión publicitaria presentan distribuciones adecuadas para el modelamiento y muestran relaciones positivas con las ventas, especialmente en los medios de TV y radio. Las correlaciones evidenciaron relaciones principalmente lineales, lo que facilitó la aplicación del modelo de regresión lineal múltiple.

Los resultados del modelo indicaron que la inversión en TV y radio incrementa las ventas, siendo la radio el medio con mayor impacto marginal, mientras que la publicidad en newspaper mostró una influencia mínima. Además, el alto valor de R^2 (0.8972) evidenció que el modelo explica gran parte de la variabilidad de las ventas, demostrando un buen ajuste.

El árbol de decisión confirmó la importancia de la inversión en TV como principal variable explicativa y permitió interpretar los resultados mediante reglas de segmentación. La regresión lineal ofrece mayor precisión predictiva, mientras que el árbol de decisión brinda una interpretación más intuitiva, siendo ambas técnicas complementarias para el análisis predictivo y la toma de decisiones.